

DEUXIÈME ANNÉE DE LICENCE

Mathématiques et informatique appliquées aux sciences humaines et sociales
(MIASHS)

Enseignement : Science des Données

Encadrante : Nefissa Khiari | Période : Novembre 2025

Analyse d'images d'anime par apprentissage supervisé : One Piece

&

Exploration non supervisée d'un corpus de citations d'œuvres animées

Hounsa Tylden, 22412555

Fenina sara, 22411291

Résumé du Rapport :

Ce travail repose sur deux volets distincts : une **classification supervisée d'images de personnages d'anime** et une **analyse non supervisée de citations issues d'œuvres animées**.

Le premier volet, consacré à l'identification de personnages de l'anime *One Piece* repose sur un protocole strict séparant 80 images d'entraînement et 20 images de test, importées via deux modules afin d'éviter toute fuite d'informations. Les images d'apprentissage sont converties en embeddings visuels V3 avant d'être soumises à plusieurs modèles de classification. Les résultats internes, obtenus par validation croisée, montrent une nette supériorité de la régression logistique qui surpasse le Réseau de Neurones et le SVM, là où l'Arbre de décision montre ses limites. La validation sur données inédites confirme la robustesse du modèle retenu.

Le second volet a été conduit sur un corpus de citations d'anime, transformé en embeddings textuels. L'utilisation de la pondération IDF et de la distance cosinus a permis d'émerger spontanément des structures sémantiques cohérentes, révélant des tendances thématiques ou stylistiques propres aux différentes œuvres, sans intervention humaine sur la structure des groupes. Cette analyse démontre la capacité des algorithmes à distinguer les registres thématiques (sport, stratégie, drame) sans étiquetage préalable.

L'ensemble du rapport met en avant une méthodologie rigoureuse, adaptée à des volumes de données modestes, et démontre l'intérêt de mobiliser à la fois des techniques supervisées et non supervisées pour analyser des contenus visuels et textuels de manière conjointe.

Table des matières :

<u>1. Apprentissage supervisé :</u>	<u>3</u>
<u>a. Jeu de Données :</u>	<u>3</u>
• <u>Phase d'Apprentissage :</u>	<u>3</u>
• <u>Phase d'Evaluation :</u>	<u>4</u>
• <u>Synthèse :</u>	<u>4</u>
<u>b. Chaîne de Traitement :</u>	<u>5</u>
<u>i. Prétraitement :</u>	<u>5</u>
<u>ii. Classification :</u>	<u>6</u>
<u>a. KNN :</u>	<u>6</u>
<u>b. Neural Network :</u>	<u>6</u>
<u>c. Tree :</u>	<u>7</u>
<u>d. Random Forest :</u>	<u>7</u>
<u>e. Logistical Regression :</u>	<u>7</u>
<u>f. SVM :</u>	<u>7</u>
<u>iii. Interprétation :</u>	<u>8</u>
<u>1. Analyse interne : Test & Score :</u>	<u>8</u>
<u>2. Analyse externe : Prédictions sur images inédites.....</u>	<u>12</u>
<u>2. Apprentissage non supervisé :</u>	<u>13</u>
<u>2.a. Jeux de données.....</u>	<u>13</u>
<u>2.b. Chaîne de traitement.....</u>	<u>14</u>
<u>i. Prétraitement (Text Preprocessing).....</u>	<u>14</u>
<u>ii. Vectorisation et Calcul de Distances.....</u>	<u>15</u>
<u>iii. Classification Hiérarchique (Clustering).....</u>	<u>17</u>
<u>2.c. Interprétation des Résultats.....</u>	<u>17</u>
<u>i. Analyse des Clusters.....</u>	<u>17</u>
<u>ii. Discussion et Ambiguïté.....</u>	<u>18</u>

1. Apprentissage supervisé :

a. Jeu de Données :

Le jeu de données utilisé pour cette étude est composé d'images de personnages One Piece, réparties en classe explicitement étiquetées, provenant du jeu de données Kaggle : [One Piece image classifier](#) . Quatre personnages de l'anime One Piece ont été retenus :

Nami , Rayleigh , Law et Crocodile .

- *Phase d'Apprentissage :*

Pour chaque personnage, un ensemble de 20 images (**Fig 1**) ont été sélectionnés de la base de données manuellement afin de constituer l'échantillon d'apprentissage.

Les images ont été organisées en quatre dossiers distincts correspondant à chaque classe.

Les images retenues présentaient des conditions “ normales”, C'est-à-dire sans rotation, déformation, texte ou filtre particuliers, afin de maintenir une cohérence visuelle et de réduire la variabilité vectorielle pendant l'entraînement.




Fig 1 : L'ensemble des images de la phases d'Apprentissage par le widget Orange Image Viewer*

- *Phase d'Évaluation :*

Un second dossier indépendant a été créé pour l'évaluation. Celui-ci contient 5 images supplémentaires par personnage, absentes du jeu d'apprentissage. Ces images (**Fig 2**) sont nommées selon la convention *personnages* (ex : *Law 1*, *Law 2*, *Law 3*, *Law4*, *Law5*).




Fig 2 : L'ensemble des images de la phases d'Évaluation par le widget Orange Image Viewer

- *Synthèse :*

La séparation apprentissage/test assure une évaluation impartiale. Le dataset respecte donc une répartition de 80% apprentissage et 20% test, soit :

- 80 images pour l'apprentissage
- 20 images pour l'évaluation
- 100 images au total

Chaque image constitue un individu. L'unique variable explicative est l'image brute, et la variable cible est le nom du personnage représenté.

b. Chaîne de Traitement :

La chaîne de traitement a été réalisée dans Orange Data Mining, en utilisant une suite de widgets adaptées à la classification supervisée d'images. Celle ci (**Fig 3**) suit une progression opérationnelles cohérente, articulée autour des étapes suivantes:




Fig 3 : Chaîne de traitement de la classification supervisé avec Orange Data Mining

i. Prétraitement :

- **Importation structuré du dataset :**

L'outil *Images Import* a été utilisé pour importer séparément :

- le dossier *Training Images*
- le dossier *Test Images*

Cette séparation explicite évite toute contamination entre les phases d'apprentissages et d'évaluation.

- **Standardisation et uniformisation des images :**

L'outil utilisé est *Images Embedding*.

L'extraction de caractéristiques s'appuie sur un modèle pré entraîné Inception V3 pour produire des vecteurs numériques afin d'alimenter les classifieurs Orange. Ces valeurs peuvent ensuite être observées sous forme tabulaire par le widget *Data table*

ii. Classification :

Six modèles supervisés ont été entraînés et évalués :

- KNN
- Neural Network
- Tree
- Random Forest
- Logistical Regression
- SVM

La validation interne utilise une cross-validation à 10 folds. Avec 80 images d'apprentissage, ce découpage représente un compromis entre stabilité statistique et qualité d'estimation.

a. KNN :

Méthode basée sur la proximité dans l'espace des embeddings. La décision repose sur les voisins les plus proches. Simple et efficace lorsque les distances sont pertinentes et dont les paramètres sont : (**Fig 4**)




Fig 4 : Paramètres du modèle KNN

b. Neural Network :

Classifieur à couches denses capable de modéliser des frontières complexes, ayant de performances dépendantes de l'architecture interne mais souvent efficaces sur embeddings profonds et dont les paramètres sont : (**Fig 5**)




Fig 5 : Paramètres du modèle Neural Network 6

c. Tree :

Arbre de décision avec segmentation hiérarchique. Ayant des méthode rapide, interprétable, mais sensible au sur-apprentissage et dont les paramètres sont : (Fig 6)




Fig 6 : Paramètre du modèle Tree

d. Random Forest :

Combinaison d'arbres de décision. Plus robuste que l'arbre simple et meilleure généralisation, réduction de la variance. Dont les paramètres sont : (Fig 7)




Fig 7 : Paramètres du modèle Random Forest

e. Logistical Regression :

Modèle linéaire performant sur embeddings de bonne qualité. Il est souvent très stable et robuste sur des vecteurs déjà bien structurés et dont les paramètres sont : (Fig 8)




Fig 8 : Paramètres du modèle Logistic Regression

f. SVM :

Méthode à marge maximale qui est performante sur des espaces de grande dimension, souvent un bon choix pour les embeddings de réseaux pré-entraînés. Dont les paramètres sont : (Fig 9)




Fig 9 : Paramètres du modèle SVM


iii. Interprétation :

La phase d'interprétation repose sur deux niveaux d'analyse :

1. Analyse interne : Test & Score :

Le widget *Test and Score* fournit les métriques de validation croisée (**Fig 10**) :

- Accuracy
- Précision
- Recall
- F1-score
- AUC



Evaluation results for target (None, show average over classes)						
Model	AUC	CA	F1	Prec	Recall	MCC
SVM	0.879	0.637	0.634	0.638	0.637	0.519
Neural Network	0.931	0.750	0.744	0.746	0.750	0.669
Logistic Regression	0.959	0.838	0.835	0.841	0.838	0.786
kNN	0.793	0.562	0.568	0.584	0.562	0.419
Tree	0.646	0.438	0.429	0.426	0.438	0.251
Random Forest	0.875	0.688	0.685	0.684	0.688	0.584

Fig 10 : Schéma du tableau Test & Score

Dans cette étude, les performances observées montrent que :

• **Logistic Regression** : Modèle le plus stable et le plus performant (meilleurs scores CA, F1, AUC, MCC). Il offre la meilleure généralisation interne avec un risque minimal de variance

• **Neural Network**: 2e meilleur AUC et CA, mais montre une légère baisse par rapport à la Régression Logistique.

• **SVM**: Solide mais nettement moins performant que les deux premiers. Ses scores F1/CA sont modérés.

• **Random forest** : Modèle très stable (faible variance) par nature. Ses performances sont modérées, se situant dans le milieu du tableau, mais il offre une bonne robustesse.

• **KNN** : Résultat faible. Les scores indiquent que la classification par proximité dans l'espace des caractéristiques ne fonctionne pas bien pour ces données.

• **Tree** : modèle le moins performant, sensible au sur-apprentissage.

- Le *Confusion Matrix* permet d'identifier les classes les plus confuses (*Fig 11* ~~ *fig 16*).

		Predicted				Σ
		Crocodile	Law	Nami	Rayleigh	
Actual	Crocodile	17	1	0	2	20
	Law	4	14	1	1	20
	Nami	0	0	20	0	20
	Rayleigh	2	1	1	16	20
Σ		23	16	22	19	80

Fig 11: confusion Matrix de Logistic Regression

		Predicted				Σ
		Crocodile	Law	Nami	Rayleigh	
Actual	Crocodile	15	2	1	2	20
	Law	3	13	1	3	20
	Nami	0	0	20	0	20
	Rayleigh	4	2	2	12	20
Σ		22	17	24	17	80

Fig 12: Confusion Matrix de Neural Network

		Predicted				Σ
		Crocodile	Law	Nami	Rayleigh	
Actual	Crocodile	10	5	1	4	20
	Law	3	12	1	4	20
	Nami	0	0	17	3	20
	Rayleigh	3	1	4	12	20
Σ		16	18	23	23	80

Fig 13: Confusion Matrix de SVM

		Predicted				Σ
		Crocodile	Law	Nami	Rayleigh	
Actual	Crocodile	8	6	2	4	20
	Law	5	9	2	4	20
	Nami	3	2	13	2	20
	Rayleigh	3	5	7	5	20
Σ		19	22	24	15	80

Fig 14 : Confusion Matrix de Tree

		Predicted				Σ
		Crocodile	Law	Nami	Rayleigh	
Actual	Crocodile	9	5	0	6	20
	Law	3	13	0	4	20
	Nami	1	2	15	2	20
	Rayleigh	5	6	1	8	20
Σ		18	26	16	20	80

Fig 15: Confusion Matrix de KNN

		Predicted				Σ
		Crocodile	Law	Nami	Rayleigh	
Actual	Crocodile	11	4	0	5	20
	Law	4	14	0	2	20
	Nami	0	0	18	2	20
	Rayleigh	3	1	4	12	20
Σ		18	19	22	21	80

Fig 16 : Confusion Matrix de Random Forest

Si on observe le confusion matrix de Logistical regression , avec le taux de classification erronée le moins élevé : 13 erreurs prédictives sur 20 en tout. La matrice montre que le modèle reconnaît correctement les quatre classes mais avec des niveaux de fiabilité différents : Crocodile et Rayleigh obtiennent chacun 17 et 16 prédictions justes sur 20, ce qui reste correct mais avec une proportion non négligeable d'erreurs, principalement vers l'autre classe où on peut observer pour Crocodile 2 erreurs de prédiction classée comme Rayleigh et inversement. Nami est parfaitement identifiée avec 20/20, ce qui indique une séparation visuelle claire et cohérente de cette classe dans l'espace des caractéristiques ; Law est le plus problématique avec seulement 14 prédictions correctes sur 20 et des confusions notables vers Crocodile , ce qui confirme que les features extraites ne séparent pas bien Law des autres profils. L'ensemble valide donc l'idée que certaines classes sont nettement séparées alors que d'autres restent partiellement superposées, ce qui limite la précision globale du modèle.

- La visualisation *MDS* permet d'observer la distribution globale des embeddings et de vérifier la séparation entre classes (**Fig 17**).




Fig 17 : schéma du nuage de similarité de MDS




Fig 18 : Ensemble d'images qui contiennent des similitudes d'après la répartition de MDS

La projection MDS montre que les images (**Fig 18**) groupées et reliées entre elles partagent des caractéristiques visuelles similaires selon les descripteurs utilisés, ce qui indique qu'un modèle supervisé risque de les confondre puisqu'elles apparaissent proches dans l'espace des features ; le gros noyau central traduit un chevauchement important entre plusieurs personnages, alors que les points isolés à droite ou en périphérie représentent des images plus distinctes et donc plus faciles à classer ; cette visualisation confirme simplement que certaines classes sont mal séparées et que la similarité perçue par l'algorithme ne correspond pas toujours aux catégories réelles, ce qui peut entraîner une classification moins fiable. D'où le taux d'erreur démontré par *Confusion Matrix*, où on peut observer surtout des erreurs pour crocodile et Law (Hypothétiquement de part leur couleur de cheveux et accessoires) mais aussi crocodile et rayleigh (Hypothétiquement de part leur longueur de cheveux et variabilité d'expression).

Par exemple, si les personnages Law et Crocodile (ici avec le taux d'erreur le plus élevées de faux positif) sont parfois confondus avec l'autre classe ou Rayleigh, cela peut provenir :

- de similarités visuelles dans certaines images
- d'un échantillon d'entraînement insuffisant
- d'une variabilité intra-classe élevée étant données que le type de dessin de l'anime a évolué au cours du temps

Les images qui ont provoqué ces prédiction, faussement positives, se déterminent possiblement par des similitudes (**Fig 19 ~ ~ Fig 21**) :




Fig 19 : L'ensemble des images de Law prédite en Crocodiles

Les similitudes que ces images peuvent avoir avec Crocodiles sont peut être les couleur (de cheveux d'accessoires) et le profil rapproché (zoom sur le visage)




Fig 20 : L'ensemble des images de Crocodiles prédite en Rayleigh

Les similitudes que les images de Crocodile peuvent avoir avec Rayleigh sont peut être les expression du visage et les cheveux




Fig 21 : l'ensemble des images de Rayleigh prédite en Crocodile

2. Analyse externe : Prédictions sur images inédites

Les 20 images de test externes sont traitées par un second *Image Embedding*, puis classées via le widget *Predictions*.

Cette étape valide la capacité réelle du modèle à généraliser hors des données internes.

Les résultats externes, à partir du tableau de prédiction (**Fig 22**), confirment globalement les observations internes :

- **Logistic Regression** (18 prédiction positives) and **Neural Network** (16 prédiction positives) restent les plus fiables ; une erreur pour le premier et
- L'arbre de décision montre un taux d'erreurs nettement supérieur (11 prédiction positives)
- Certaines images ambiguës (ex :postures inhabituelles, faible qualité) induisent des confusions récurrentes

La comparaison interne/externe permet de montrer que le modèle ne se contente pas de mémoriser les images d'apprentissage, mais apprend bien une structure exploitable.

En observant les prédictions de Logistic Regression (**Fig 22**) ;Le modèle affiche un taux de précision élevé de 90%, confirmant sa grande stabilité et sa capacité à généraliser les patterns appris à de nouvelles observations non vues lors de l'entraînement. Ce score est un indicateur fort de la robustesse du modèle pour la tâche de classification définie.

Deux erreurs de classification ont été observées et donc deux images mal prédite (**Fig 23**) . Les instances concernées sont :

Instances Mal Classée (Réalité) : Le personnage de Crocodile4 et Rayleigh5

Classe Prédite (Erreur) : Le personnage de Law et Nami

Predictions - Orange												
Show probabilities for: (None)												Restore Original Order
	Logistic Regression (1)	Neural Network (10)	Random Forest (1)	SVM (1)	XNN (1)	Tree (1)	image name	image	size	width	height	
1	Crocodile	Crocodile	Crocodile	Crocodile	Crocodile	Crocodile	crocodile1	crocodile1.png	247870	600	450	0.15929
2	Crocodile	Crocodile	Crocodile	Crocodile	Crocodile	Crocodile	crocodile2	crocodile2.png	478638	574	1124	0.42694
3	Crocodile	Crocodile	Crocodile	Crocodile	Crocodile	Crocodile	crocodile3	crocodile3.jpg	54569	735	735	0.16007
4	Law	Law	Law	Law	Law	Crocodile	crocodile4	crocodile4.jpg	112104	731	1400	0.16136
5	Crocodile	Rayleigh	Crocodile	Crocodile	Crocodile	Nami	crocodile5	crocodile5.png	77049	300	300	0.88481
6	Law	Law	Rayleigh	Rayleigh	Law	Rayleigh	law1	law1.png	249162	325	568	0.15096
7	Law	Law	Law	Law	Law	Law	law2	law2.png	291863	640	360	0.06468
8	Law	Law	Law	Law	Law	Crocodile	law3	law3.jpg	30110	543	642	0.14048
9	Law	Law	Rayleigh	Rayleigh	Rayleigh	Crocodile	law4	law4.jpg	133244	1080	1080	0.21089
10	Law	Law	Law	Law	Law	Nami	law5	law5.png	91537	458	459	0.35088
11	Nami	Nami	Nami	Nami	Nami	Nami	nami1	nami1.png	30315	317	180	0.06725
12	Nami	Nami	Nami	Nami	Nami	Nami	nami2	nami2.png	115896	225	224	0.10563
13	Nami	Nami	Nami	Nami	Rayleigh	Nami	nami3	nami3.jpg	143846	1080	1080	0.20108
14	Nami	Nami	Rayleigh	Rayleigh	Rayleigh	Crocodile	nami4	nami4.jpg	85374	720	720	0.07943
15	Nami	Nami	Nami	Nami	Nami	Rayleigh	nami5	nami5.png	100652	225	225	0.39587
16	Rayleigh	Rayleigh	Rayleigh	Rayleigh	Nami	Rayleigh	rayleigh1	rayleigh1.png	435705	637	587	0.17048
17	Rayleigh	Rayleigh	Rayleigh	Rayleigh	Rayleigh	Nami	rayleigh2	rayleigh2.png	773690	636	636	0.27035
18	Rayleigh	Nami	Law	Rayleigh	Rayleigh	Rayleigh	rayleigh3	rayleigh3.webp	26584	500	607	0.38622
19	Rayleigh	Rayleigh	Crocodile	Rayleigh	Nami	Rayleigh	rayleigh4	rayleigh4.webp	11600	560	382	0.05419
20	Nami	Law	Law	Nami	Law	Law	rayleigh5	rayleigh5.png	77185	166	257	0.44735

Fig 22 : Tableau des prédictions de classe à partir des données de Test




Fig 23 : Schéma des images erroné prédite par Logistic Regression sur Prédiction

Ces deux erreurs représentent un cas d'ambiguïté résiduelle dans l'espace des caractéristiques. Elle suggère que les attributs (features) décrivant l'individu *Law* présentent une proximité significative avec le profil des individus classés comme *Crocodile*. La frontière de décision (séparant les classes dans le modèle) a donc malencontreusement attribué l'image de Crocodile à la mauvaise catégorie "*Law*". Ce qui confirme l'interprétation observée par l'analyse externe même avec des données indépendantes.

En ce qui concerne *Rayleigh5*, on peut observer des erreurs de classification pour tous les modèles utilisés, ce qui suggère une ambiguïté et une variabilité inédite par rapport aux données d'apprentissage et ce qui empêche sa bonne catégorisation.

2. Apprentissage non supervisé :

Cette seconde partie de l'étude porte sur l'analyse exploratoire d'un corpus textuel. Contrairement à la classification d'images précédente, il s'agit ici d'une approche non supervisée : l'algorithme doit découvrir par lui-même des structures ou des thématiques communes au sein de citations d'animes, sans utiliser les étiquettes des séries comme vérité terrain lors de l'apprentissage.

2.a. Jeux de données

Le jeu de données (dataset) est constitué d'un corpus de citations extraites de divers animes, issues initialement d'une base de données publique Kaggle: [Anime Quotes Dataset](#).

Pour les besoins de cette étude spécifique, un sous-ensemble contrôlé a été constitué en retenant quatre œuvres aux registres distincts :

- **Nana** (Romance / Drame / Tranche de vie)
- **Tokyo Ghoul** (Horreur / Psychologique)
- **Haikyuu** (Sport / Esprit d'équipe)
- **Code Geass** (Stratégie / Politique / Mecha)

Composition de l'échantillon :

Un échantillonnage équilibré a été réalisé en sélectionnant aléatoirement 15 citations pour chaque anime, soit un total de 60 citations.

- **Individus** : Chaque citation constitue un individu statistique.
- **Variables** :
 - *Variable textuelle* : Le contenu de la citation (en anglais).
 - *Target de comparaison* : Le titre de l'anime d'origine.

L'objectif est de vérifier si le vocabulaire utilisé permet de regrouper naturellement ces citations selon leur aïme d'appartenance ou selon des thématiques transversales.

2.b. Chaîne de traitement

La chaîne de traitement (*Fig 1*) a été élaborée sous Orange Data Mining en utilisant l'extension *Text Mining*. Elle suit une logique de transformation progressive des données non structurées vers une représentation vectorielle exploitable par des algorithmes de distance.




Fig 1 : Chaîne de traitement globale pour le clustering de textes sous Orange

i. Prétraitement (Text Preprocessing)

Le texte brut contient souvent du "bruit" qui peut fausser les calculs de similarité. Une

phase rigoureuse de nettoyage sera donc nécessaire.

1. Importation et Corpus :

L'outil CSV File Import charge les données brutes et les fournit au widget Corpus qui transforme ensuite ces chaînes de caractères en objets textuels manipulables (Fig 2), en désignant la colonne "Quote" comme contenu et "Anime" comme méta-information.




Fig 2 : Paramètres d'importation du fichier csv dans la chaîne de traitement

2. Nettoyage (Widget Preprocess Text) :

Une série de filtres a été appliquée pour normaliser le texte :

- **Transformation (Lowercase)** : Conversion de tous les caractères en minuscules pour assurer que "Team" et "team" soient traités identiquement.
- **Tokenization (RegExp)** : Découpage du texte en unités élémentaires (mots), en supprimant la ponctuation.
- **Filtering (Stopwords)** : Suppression des mots vides (articles, pronoms, verbes d'état courants comme "the", "is", "of") via une liste standard anglaise enrichie manuellement grâce au fichier stopwords.txt. Ces mots, bien que fréquents, n'apportent pas de valeur sémantique discriminante.



Fig 3 : Nuage de mots (Word Cloud) avant et après prétraitement, montrant les termes significatifs.

ii. Vectorisation et Calcul de Distances

Pour appliquer des algorithmes mathématiques, le corpus textuel nettoyé doit être converti en matrice numérique.

- Bag of Words (Sac de mots) :

Le widget Bag of Words est utilisé ici pour compter les occurrences de chaque terme dans chaque citation (Fig 4). Une pondération TF-IDF (Term Frequency-Inverse Document Frequency) a été privilégiée au simple comptage, afin de donner plus de poids aux mots spécifiques à une citation et moins aux termes génériques apparaissant partout.




Fig 4 : Paramètres de l'outil Bag of words

- Matrice de Distances (Fig 5):

Le widget Distances lui calcule la dissemblance entre chaque paire de citations.

- *Métrique choisie* : **Cosinus**. Contrairement à la distance Euclidienne, la distance Cosinus mesure l'angle entre deux vecteurs. Elle est particulièrement adaptée au *Text Mining* car elle évalue la similarité de profil (thématique) indépendamment de la longueur de la citation.
- *Note technique* : L'outil **Distances** émet un avertissement d'**ignorance des variables catégorielles (Ignoring categorical features)**. Cela est normal et souhaité : la distance Cosinus étant purement vectorielle, elle utilise uniquement les poids TF-IDF et ignore les méta-données textuelles (Anime, Character) qui ne sont pas exploitables mathématiquement pour ce type de métrique.




Fig 5 : Visualisation des paramètres de l'outil distance




Fig 6 : Visualisation de la matrice de dissemblance calculée avec la métrique Cosinus.

Les valeurs sont comprises entre 0 (similitude parfaite) et 1 (dissimilarité maximale). Les zones de faible distance (couleurs claires/bleues) entre certaines citations indiquent les structures sémantiques que l'algorithme de clustering va exploiter (Fig 6).

iii. Classification Hiérarchique (Clustering)

Le regroupement a été effectué via le widget *Hierarchical Clustering* (Fig 7).

- *Méthode de lien (Linkage) : Ward.* Cette méthode minimise la variance intra-classe et tend à créer des clusters compacts et de tailles équilibrées.
- Le dendrogramme obtenu a été coupé à une hauteur permettant d'isoler **4 clusters** principaux, correspondant théoriquement au nombre d'animes présents.




Fig 7 : Dendrogramme issu de la classification hiérarchique.

2.c. Interprétation des Résultats

L'analyse des clusters formés s'appuie sur la visualisation conjointe du *Hierarchical Clustering* et du *Word Cloud* (nuage de mots dynamique par cluster).

L'examen de la composition des groupes révèle des tendances sémantiques fortes :

i. Analyse des Clusters

La coupure du dendrogramme à K=4 clusters (Fig 7), un choix justifié par le nombre d'animes distincts dans notre échantillon, a permis d'isoler les groupes suivants :

1. **Cluster 1 - La thématique de l'équipe et du jeu (Dominante *Haikyuu*):** Ce groupe est fortement caractérisé par un vocabulaire athlétique et de compétition. Les mots-clés dominants, observés dans le *Word Cloud* du cluster, sont "win", "chance", "believe", "us" et "stand". L'algorithme a réussi à isoler très nettement le vocabulaire sportif de *Haikyuu*, démontrant une dissemblance sémantique forte avec les autres œuvres.




Fig 8 : Nuage de mots du cluster 1

2. **Cluster 2 - Pouvoir et Contrôle (Dominante *Code Geass*) :** Ce cluster est centré sur les concepts de stratégie, de conflit et d'autorité. Les termes "fight", "weak", "beyond", "alone" et "enemy" dominant, reflétant les enjeux politiques et militaires de *Code Geass*. Ce groupe est bien séparé des autres, soulignant l'efficacité du TF-IDF à valoriser le vocabulaire de "conflit social" ou "guerre" par rapport aux thématiques personnelles ou sportives.





Fig 9 : Nuage de mots du cluster 2

3. **Cluster 3 - Introspection et Tragédie (Mixte *Tokyo Ghoul* / *Nana*) :** Ce cluster rassemble des termes à forte charge émotionnelle et existentielle : "pain", "losing", "wrong", "weak", "dreams". Il regroupe majoritairement les citations de *Tokyo Ghoul*, marquées par une tonalité sombre et psychologique. Cependant, ce cluster capture également un sous-ensemble de citations dramatiques issues de *Nana*.



4. **Cluster 4 - Relation et Réflexion (Dominante *Nana*)** : Ce cluster plutôt généraliste se distingue par des termes liés aux relations interpersonnelles, à la fatalité et au temps : "life", "become", "think", "best". Il représente le cœur de l'œuvre *Nana* (Romance/Drame).



ii. Discussion et Ambiguïté

L'analyse non supervisée démontre que, même sur des fragments de texte courts (citations), le modèle vectoriel TF-IDF couplé à la distance Cosinus est suffisamment discriminant pour reconstituer les catégories d'origine.

Les erreurs de classification, où des citations de *Nana et même haikyuu* se mélangent à *Tokyo Ghoul* (Cluster 3), sont cohérentes et révélatrices de l'ambiguïté sémantique. Les phrases concernées traitent de sentiments humains universels (souffrance, perte, destin). L'algorithme ne distingue pas le contexte (le drame réaliste de *Nana* vs. le drame fantastique de *Tokyo Ghoul*), mais uniquement la proximité des vecteurs de mots. Cette confusion démontre les limites de l'approche *Bag of Words* face à la nuance contextuelle, un problème qui pourrait être résolu par d'autres techniques tels que K-mean.

Conclusion partielle : Les résultats de clustering confirment que la structure sémantique du langage est fortement liée au genre de l'œuvre. Le processus d'apprentissage non supervisé a réussi à créer des regroupements thématiques logiques et corrélés aux animes sources.